



Data Challenge

Relatório Técnico

Candidato: **João Barbosa**

Stack: Python · MySQL · pandas · matplotlib · seaborn · reportlab

Nota de transparência: Claude (Anthropic) foi utilizado como apoio pontual na estruturação do código de compilação loqbox_challenge.py, generate_report.py, auxílios de sintaxe e boas práticas nos cases e escolha de bibliotecas de visualização e de geração d. A lógica SQL, o raciocínio analítico, estruturação dos diretórios, arquivos e as adaptações ao banco de dados foram realizados pelo candidato.

SQL Test

Q1 — 10 produtos mais caros

Ordenação decrescente por PRODUCT_VAL com LIMIT 10.

```
SELECT PRODUCT_COD, PRODUCT_NAME, PRODUCT_VAL
FROM data_product
ORDER BY PRODUCT_VAL DESC LIMIT 10;
```

PRODUCT_COD	PRODUCT_NAME	PRODUCT_VAL
301409	Whisky Escoces THE MACALLAN Ruby Garrafa 700ml com Caixa	741.99
176185	Whisky Escoces JOHNNIE WALKER Blue Label Garrafa 750ml	735.9
315481	Cafeteira Expresso 3 CORACOES Tres Modo Vermelho	499.0
100280	Vinho Portugues Tinto Vintage QUINTA DO CRASTO Garrafa 750ml	445.9
320046	Escova Dental Eletrica ORAL B D34 Professional Care 5000 110v	399.9
190817	Champagne Rose VEUVE CLICQUOT PONSARDIM Garrafa 750ml	366.9
153795	Champagne Frances Brut Imperial MOET Rose Garrafa 750ml	359.9
311397	Conjunto de Panelas Allegra em Inox TRAMONTINA 5 Pecas Gratis Utensilios 5 Pecas	359.0
147706	Whisky Escoces CHIVAS REGAL 18 Anos Garrafa 750ml	329.9
154431	Champagne Frances Brut Imperial MOET & CHANDON Garrafa 750ml	315.9

Q2 — Seções de BEBIDAS e PADARIA

DISTINCT em SECTION_NAME com WHERE DEP_NAME IN ('BEBIDAS', 'PADARIA').

```
SELECT DISTINCT DEP_NAME, SECTION_NAME, SECTION_COD
FROM data_product
WHERE DEP_NAME IN ('BEBIDAS', 'PADARIA')
ORDER BY DEP_NAME, SECTION_NAME;
```

Departamento	Seção	Cod_Seção
BEBIDAS	BEBIDAS	4
BEBIDAS	CERVEJAS	29
BEBIDAS	REFRESCOS	31
BEBIDAS	VINHOS	30
PADARIA	DOCES-E-SOBREMESAS	8
PADARIA	GESTANTE	27
PADARIA	PADARIA	19
PADARIA	QUEIJOS-E-FRIOS	22

Q3 — Vendas por Business Area (Q1 2019)

JOIN entre data_product_sales e data_store_cad, filtrando DATE BETWEEN '2019-01-01' AND '2019-03-31', agrupado por BUSINESS_NAME.

```
SELECT sc.BUSINESS_NAME, ROUND(SUM(ps.SALES_VALUE), 2) AS Total_Vendas
FROM data_product_sales ps
JOIN data_store_cad sc ON ps.STORE_CODE = sc.STORE_CODE
WHERE ps.DATE BETWEEN '2019-01-01' AND '2019-03-31'
GROUP BY sc.BUSINESS_NAME ORDER BY Total_Vendas DESC;
```

Business_Area	Total_Vendas
Farma	81776691.73

Business_Area	Total_Vendas
Varejo	81032347.65
Atacado	80384884.6
Proximidade	80171122.8
Posto	32072326.4

Case 1 — Função retrieve_data

Função dinâmica que constrói a cláusula WHERE apenas com os filtros fornecidos. Todos os parâmetros são **opcionais**, tornando a função reutilizável por qualquer equipe. O uso de parâmetros parametrizados (%s) evita SQL injection.

```
def retrieve_data(
    product_code: Optional[int] = None,
    store_code: Optional[int] = None,
    date: Optional[list] = None,
) -> pd.DataFrame:
    conditions, params = [], []
    if product_code: conditions.append('PRODUCT_CODE = %s')
    if store_code: conditions.append('STORE_CODE = %s')
    if date: conditions.append('DATE BETWEEN %s AND %s')
    where = 'WHERE ' + ' AND '.join(conditions) if conditions else ''
    sql = f'SELECT * FROM data_product_sales {where};'
    return pd.read_sql(sql, get_connection(), params=params or None)
```

Exemplos de uso

```
retrieve_data() # sem filtros – retorna tudo
retrieve_data(product_code=301409)
retrieve_data(store_code=3, date=['2019-01-01', '2019-03-31'])
```

Nenhum registro encontrado para os filtros de exemplo utilizados.

Case 2 — Ticket Médio por Loja (Q4 2019)

As duas queries do cliente foram usadas **sem modificação**. O filtro de período ['2019-10-01', '2019-12-31'] foi aplicado em Python após o carregamento. O Ticket Médio foi calculado como $\text{SALES_VALUE} / \text{SALES_QTY}$ por loja, seguido de JOIN com os dados cadastrais.

Loja	Categoria	TM
Bahia	Atacado	15.39
Bangkok	Posto	13.67
Belem	Proximidade	15.37
Berlin	Proximidade	15.39
Buenos Aires	Atacado	15.39
Chicago	Varejo	15.53
Dubai	Atacado	15.39
Hong Kong	Farma	26.35
London	Farma	28.99
Madri	Farma	29.03
Miami	Posto	13.67
New York	Proximidade	15.39
Paris	Proximidade	15.39
Rio de Janeiro	Farma	29.59
Roma	Varejo	15.39
Salvador	Atacado	15.39
Sao Paulo	Varejo	15.39
Sidney	Posto	13.67
Tokio	Varejo	15.39
Vancouver	Posto	13.67




Figura 1 — Ticket Médio por Loja, Q4 2019 (out-dez). Cores por categoria.

Case 3 — Análise IMDB

Visualização 1: Violin Plot — notas por década

O violin plot foi preferido ao bar chart de médias porque revela a **distribuição completa** das notas. Décadas antigas concentram notas mais altas por viés de sobrevivência: apenas os filmes mais marcantes permanecem bem avaliados ao longo do tempo — padrão invisível em barras simples.




Figura 2 — Distribuição das notas IMDB por década de lançamento.

Visualização 2: Top 10 gêneros por nota média

Bar chart horizontal dos gêneros com maior nota média (mínimo de 20 filmes para excluir gêneros com amostra insuficiente).




Figura 3 — Top 10 gêneros por nota média IMDB (mín. 20 filmes).